

FinHive:  
De la Teoria a la Practica en Arquitecturas  
Multiagente  
Un sistema jerarquico de analisis financiero, construido sobre  
Databricks

Matias Fabian Adell


Portfolio project — [github.com/matiasadell/finhive](https://github.com/matiasadell/finhive)

August 29, 2026

## De una investigacion teorica a un sistema real

- Punto de partida: un timeline propio de **24 arquitecturas agenticas** (2020–2026), organizado en seis eras narrativas — de RAG clasico a los primeros intentos de sistematizar el campo.
- La pregunta que atraviesa esas seis eras: **cuanto control de diseno se le devuelve al propio sistema** — topologia, memoria, tolerancia a fallos.
- FinHive es el ejercicio deliberado de aplicar esa cadena completa a un dominio real, en vez de quedarse en el nivel conceptual.
- Un modelo individual no alcanza para un dominio tan heterogeneo como las finanzas: macro, equities, riesgo de portfolio, noticias, cripto — cada uno con sus propias fuentes y formatos.

# Supervisor de supervisores: jerarquia de dos niveles



- Mismo patron replicado en dos niveles: un supervisor decide, con *structured output*, a que nodo delegar — hasta FINISH.
- 13 workers ReAct sobre 25 tools registradas en Unity Catalog.

## Cinco dominios especializados

| Dominio          | Fuente de datos / especialidad                                              |
|------------------|-----------------------------------------------------------------------------|
| Macro            | FRED (tasas, inflacion, indicadores)                                        |
| Equity Research  | yfinance + SEC EDGAR (fundamentals, filings XBRL)                           |
| Portfolio & Risk | <b>Computo propio:</b> VaR, volatilidad, Sharpe, correlacion (numpy/pandas) |
| News & Sentiment | Alpha Vantage (sentiment estructurado) + Tavily (fall-back CRAG)            |
| Crypto & Alt     | CoinGecko (precio, tendencias, ranking)                                     |

## Stack: 100% sobre Databricks Free Edition

- **Foundation Model APIs nativos:** Llama 3.3 70B / 3.1 8B — sin ninguna key externa.
- **Unity Catalog Functions:** 25 tools gobernadas, alternativa sin costo a los Managed MCP servers.
- **Unity AI Gateway:** routing real entre modelos + rate limits.
- **Databricks Repos:** repo de GitHub conectado, notebook demo corriendo dentro del workspace.
- **MLflow Tracing:** cada invocacion, cada tool call, trazado.

Costo total verificado: **\$0**

# De paper a decision de ingenieria

| Concepto                                       | Donde vive en FinHive                                                    |
|------------------------------------------------|--------------------------------------------------------------------------|
| ReAct (Yao et al., 2022)                       | Los 13 workers hoja                                                      |
| Corrective RAG                                 | Fallback a Tavily cuando Alpha Vantage no alcanza                        |
| Multi-Agent Supervisor / Jerarquica (TalkHier) | Los dos niveles de la topologia completa                                 |
| Mixture-of-Agents                              | Sintesis cuando una pregunta cruza 2+ dominios                           |
| MCP (concepto)                                 | Unity Catalog Functions gobernadas, sin el costo del servicio gestionado |
| LLM Gateway                                    | Unity AI Gateway: routing, rate limits, usage tracking                   |

# Hallazgo: un bug de plataforma causa una alucinacion

**El problema:** el modo recomendado para tools de Unity Catalog (UCFunctionToolkit local) genera un subprocesso que hace `import resource` — **modulo que solo existe en Unix**. En Windows falla silenciosamente.

**La consecuencia real:** el worker, sin dato, **alucino una cifra plausible** (5.25% de tasa de fondos federales) en vez de admitir el fallo. El valor real, verificado por separado: **3.63%**.

“Un fallo silencioso de tool es indistinguible de un dato real.”

## Hallazgo: ruteo entre dominios y su costo real

- Pregunta: “¿cuando es el proximo earnings de Apple?”
- Se enruto a **Equity** en vez de **News & Sentiment** — el router solo veia *nombres* de equipo, sin limites explicitos.
- Equity, sin la tool de calendario, **alucino una fecha incorrecta** (2025 en vez de 2026).

**Correccion:** descripciones explicitas por equipo, con lineas de “*esto NO es de este equipo*” en los casos de frontera — aplicado preventivamente al sumar el quinto dominio, antes de que apareciera el mismo bug.

## Unity AI Gateway: routing real, verificado empiricamente

finhive\_router: 70% del trafico a Llama 3.3 70B, 30% a GPT OSS 120B.

**No solo configurado — verificado con 6 llamadas reales:**

| 1     | 2     | 3     | 4       | 5     | 6     |
|-------|-------|-------|---------|-------|-------|
| Llama | Llama | Llama | GPT-OSS | Llama | Llama |

ChatDatabricks todavia no soporta este path nuevo de API — se resolvio con el cliente OpenAI-compatible (`langchain_openai.ChatOpenAI`) que Databricks expone directamente, sin esperar a la libreria especializada.

# Resultados

- 5 dominios completos, verificados extremo a extremo contra APIs reales.
- 13 workers ReAct sobre 25 Unity Catalog Functions.
- 6 tests de integracion — cada uno verifica *grounding* real, no solo ausencia de excepciones.
- \$0 de costo total de LLM y embeddings, verificado en vivo.
- 10 ADRs documentando cada decision y cada hallazgo con su razonamiento.

## Trabajo futuro

- Guardrails formales (topico, seguridad, *groundedness*) — motivados directamente por los hallazgos de este proyecto.
- Memoria persistente (patron MemGPT).
- RAG estilo RAPTOR sobre el texto completo de 10-K/10-Q.
- Mosaic AI Agent Framework + evaluacion CLEARs.
- Demo desplegada como Databricks App.

# ¡Gracias!

Codigo completo, ADRs, y notebook demo:  
[github.com/matiasadell/finhive](https://github.com/matiasadell/finhive)

¿Preguntas o feedback? Bienvenidos.